

Dự đoán giá bán nhà tại Ames bằng học máy và mạng nhiều lớp

Báo cáo Lab 03 | Bộ dữ liệu House Prices Advanced Regression Techniques

Phân công công việc

Bảng dưới đây được để trống để nhóm tự điền.

Họ tên	Mã sinh viên	Công việc	Tỷ lệ đóng góp

Tóm tắt

Bài toán là dự đoán giá bán SalePrice của nhà ở Ames, Iowa từ 79 thuộc tính. Tập có nhãn gồm 1.460 căn nhà; 1.459 căn nhà còn lại chỉ dùng để xuất dự đoán. Chúng tôi so sánh Ridge và HistGradientBoosting trong scikit-learn với mạng MLP viết bằng PyTorch. Nhóm đặc trưng tổng diện tích nhà và hiện cải thiện điểm log RMSE kiểm định chéo của HistGradientBoosting từ 0,1383 xuống 0,1345 (khoảng 2,7%). Mô hình được chọn đạt 0,1378 trên 292 mẫu giữ lại.

1 Bài toán và tài liệu nền

De Cock (2011) giới thiệu bộ Ames gốc gồm 2.930 giao dịch nhà ở giai đoạn 2006–2010 và 80 biến mô tả. Bài báo đề xuất dự đoán giá bằng hồi quy, kiểm tra tính phù hợp của mô hình và thử tạo biến mới. Bài báo tách MODEL1 để diễn giải khỏi MODEL2 tối ưu dự đoán bằng tập kiểm định; bài này theo hướng MODEL2. Tác giả cũng lưu ý năm căn nhà trên 4.000 ft² có thể làm mô hình nhạy với ngoại lệ. PDF hướng dẫn Kaggle dùng một bản chia khác của dữ liệu: 1.460 dòng có nhãn, 1.459 dòng không có nhãn và 79 biến giải thích sau khi bỏ Id. Vì vậy kết quả trong báo cáo là cho bản Kaggle, không phải toàn bộ 2.930 giao dịch của paper.

PDF code minh họa tải train.csv/test.csv, xử lý giá trị thiếu, mã hóa thuộc tính và thử XGBoost, cây quyết định, mạng Keras. Bài này viết lại quy trình bằng các thư viện được yêu cầu. Cây phân loại không phù hợp với SalePrice liên tục nên chúng tôi dùng các bộ hồi quy. Chúng tôi cũng giữ riêng dữ liệu đánh giá khi học bộ điền thiếu và chuẩn hóa để tránh rò rỉ dữ liệu.

2 Dữ liệu và tiêu chí đánh giá

Dữ liệu CSV không nằm trong thư mục nguồn ban đầu; bản sao công khai khớp 1.460 × 81 và 1.459 × 80 được lưu trong data/. SalePrice có trung vị 163.000 USD, nhỏ nhất 34.900 USD và lớn nhất 755.000 USD. Các cột thiếu nhiều gồm PoolQC (1.453/1.460), Alley (1.369), Fence (1.179) và LotFrontage (259). MSSubClass được coi là mã loại nhà; sau khi bỏ Id, đầu vào gồm 35 biến số và 44 biến phân loại.

Tiêu chí chính theo Kaggle là căn bậc hai của trung bình bình phương chênh lệch giữa log(giá dự đoán) và log(giá thật). Giá đều dương. MAE theo USD được báo thêm để dễ diễn giải. Tập test Kaggle không có SalePrice nên không thể tự tính điểm của tập này.

3 Thiết kế thực nghiệm

Seed cố định là 42. Từ 1.460 dòng có nhãn, 1.168 dòng (80%) dùng phát triển mô hình và 292 dòng (20%) làm tập giữ lại. Ba nếp KFold có xáo trộn chỉ chạy trên phần phát triển. Mỗi nếp học riêng phép điền trung vị cho số, giá trị Missing cho phân loại, one-hot cho phân loại và chuẩn hóa số. Chưa biết loại mới thì mã hóa thành toàn số 0 ở nhóm đó. Đích học là $\log(\text{SalePrice})$, dự đoán xuất ra bằng exp.

Ridge dùng $\alpha = 20$. HistGradientBoosting dùng 150 vòng, tối đa 15 lá và $L2 = 1$. MLP có hai lớp ẩn 128 và 64 nút ReLU, dropout 0,15, AdamW và dừng sớm sau 25 epoch không tiến bộ. Trong từng nếp, MLP lấy 15% của phần huấn luyện làm tập dừng sớm; tập giữ lại cuối không tham gia bước này.

4 Tìm kiếm đặc trưng

Nhóm	Đặc trưng mới so với nhóm trước
raw	79 cột gốc; bỏ ld và đích SalePrice
area	TotalHouseSF = GrLivArea + TotalBsmtSF; TotalPorchSF = tổng 4 loại hiên
area_age_bath	TotalBath; HouseAgeAtSale; YearsSinceRemodel
all	QualityLivingArea; QualityTotalArea = chất lượng $\times$ diện tích

Các tuổi được tính theo YrSold của từng giao dịch, không dùng năm hiện tại. MLP được thử với raw và all để đo tác động của gói đặc trưng đầy đủ; hai mô hình scikit-learn được thử với cả bốn nhóm.

5 Kết quả

Bảng 1. Trung bình log RMSE của ba nếp kiểm định chéo trên phần phát triển (thấp hơn là tốt hơn).

Mô hình	Nhóm đặc trưng	Trung bình	Độ lệch chuẩn
HistGradientBoosting	area	0.1345	0.0199
HistGradientBoosting	area_age_bath	0.1350	0.0194
HistGradientBoosting	all	0.1352	0.0198
HistGradientBoosting	raw	0.1383	0.0206
Ridge	raw	0.1502	0.0469
Ridge	area	0.1505	0.0477
Ridge	area_age_bath	0.1506	0.0476
PyTorch MLP	raw	0.1507	0.0295
Ridge	all	0.1523	0.0528
PyTorch MLP	all	0.1653	0.0331

Với HistGradientBoosting, nhóm area cho điểm tốt nhất: 0,1345 so với 0,1383 khi chỉ dùng cột gốc, cải thiện 0,0038 log RMSE (2,7%). Thêm tuổi, phòng tắm hoặc tương tác chất lượng–diện tích không cải thiện tiếp. Ridge tốt nhất ở raw (0,1502). MLP cũng tốt nhất ở raw (0,1507); thêm toàn bộ đặc trưng làm điểm xấu đi thành 0,1653.

Bảng 2. Đánh giá một lần trên 292 mẫu giữ lại với nhóm đặc trưng tốt nhất của từng mô hình.

Mô hình	Đặc trưng	Log RMSE	MAE (USD)
Ridge	raw	0.1379	16,464
HistGradientBoosting	area	0.1378	15,947
PyTorch MLP	raw	0.1395	16,845

6 Diễn giải và giới hạn

Mô hình được chọn bằng trung bình điểm kiểm định chéo trên 1.168 dòng phát triển là HistGradientBoosting với area. Điểm 0,1378 trên tập giữ lại chỉ nhỉnh hơn Ridge raw (0,1379), nên không thể kết luận chênh lệch trên dữ liệu mới là lớn. Độ lệch chuẩn của các nếp cũng cho thấy kết quả phụ thuộc cách chia dữ liệu. Trong nếp thứ hai, hai căn nhà Id 1299 và 524 có diện tích sống trên 4.000 ft² và SaleCondition = Partial; chúng góp phần làm điểm Ridge tăng mạnh. Chúng tôi giữ nguyên các dòng này ở đánh giá để đo đúng độ khó của dữ liệu Kaggle, đồng thời ghi nhận khuyến nghị kiểm tra ngoại lệ của De Cock.

Mẫu chỉ có 1.460 dòng nên MLP dễ bất ổn dù có dropout và dừng sớm. Đây là một cấu hình MLP cố định, không phải tìm kiếm siêu tham số toàn diện. Các đặc trưng mới có ý nghĩa vật lý nhưng có tương quan với cột gốc; vì vậy mô hình không luôn hưởng lợi khi thêm chúng. Không có điểm Kaggle công bố cho submission.csv trong báo cáo này.

7 Kết luận và cách kiểm tra lại

Hai đặc trưng tổng diện tích là thay đổi hiệu quả nhất trong phép thử với HistGradientBoosting. Chạy python run_experiments.py để tạo lại cv_results.csv, cv_summary.csv, holdout_results.csv và submission.csv; chạy python test_pipeline.py để kiểm tra công thức đặc trưng, rò rỉ tiền xử lý và cấu trúc file nộp. Mã, dữ liệu và kết quả đo được kèm trong gói nộp.

Tài liệu tham khảo

- [1] De Cock, D. (2011). Ames, Iowa: Alternative to the Boston Housing Data as an End of Semester Regression Project. Journal of Statistics Education, 19(3). File decock.pdf do đề bài cung cấp.
- [2] Nimje, R. House Prices: Advanced Regression Techniques. PDF minh họa do đề bài cung cấp, <https://risx3.github.io/house-prices/>.
- [3] Kaggle. House Prices: Advanced Regression Techniques, dữ liệu và quy tắc đánh giá, <https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques/>.
- [4] Ayeshaa-Aslam. Bản sao công khai các file CSV Kaggle, <https://github.com/Ayeshaa-Aslam/House-Prices-Advanced-Regression-Techniques>.